AI Agent 工程模式速查手册

193 个模式 · 13 个主题 · 证据等级标注 · 问题树导航

一份可以放进工具箱的 Agent 工程参考地图：

- **13 个主题、193 个模式**，每条附一句话说明与证据等级标注（● 生产验证 / ★ 成熟 / ◐ 新兴 / ○ 提案或实验）
- **常见问题速查**：15 类高频工程问题 → 推荐模式与所在章节
- **问题树导航**：T1–T4 四部结构（能力 / 可靠 / 演化 / 边界），从根问题到具体模式
- **证据底座**：源自 221 篇研究报告（Anthropic / OpenAI / Microsoft / Cursor / Sourcegraph / Cloudflare 六家平台的生产数据，2022–2026）

作者：冯海泉 · 2026 年 10 月 · v1.0

目录

全书按问题树组织：**T1 能力**（怎么做到）→ **T2 可靠**（如何不出错）→ **T3 演化**（如何越用越好）→ **T4 边界**（如何与人和成本共处）。先按问题定位主题，再进章节速查选型。

部	T码	章 · 主题	问题句	模式数	页
导引	—	2 常见问题速查	15 类高频工程问题 → 推荐模式	15 条	—
第一部 能力	T1.1.1	3 上下文	有限窗口内，什么信息何时以何形式存在?	25	—
	T1.1.2	4 推理	多少算力换多少推理质量?	8	—
	T1.2.1	5 工具	工具如何被发现、选择、安全执行、协同?	20	—
	T1.3.1	6 架构	控制流、并行度、自主性各放在谱系何处?	40	—
	T1.3.2	7 多智能体	何时拆分、拆成什么拓扑、如何防污染?	15	—
第二部 可靠	T2.1.1	8 质量	错误在哪一阶段被哪道防线拦截?	25	—
	T2.1.2	9 安全	信任边界画在哪里？三要素如何切断?	20	—
第三部 演化	T3.1.1	10 学习	学习发生在哪一层位面?	11	—
	T3.1.2	11 可观测性	非确定系统如何可见、可判定、可反馈、可固化?	6	—
	T3.1.3	12 代码审查	谁审查 AI 的代码？代码库如何为 AI 重构?	4	—
第四部 边界	T4.1.1	13 人机协作	自主性给多少？如何无缝切换?	4	—
	T4.1.2	14 开发者体验	开发栈如何为两个用户重构?	12	—
	T4.2.1	15 成本与性能	钱在生命周期哪个阶段以什么策略花?	3	—
附录	—	署名与来源声明	上游来源、修改声明与许可	—	—
	—	Apache License 2.0	上游 LICENSE 全文	—	—

> 各章末尾附"跨主题收录"：在旧分类下也归属该主题、但物理收录于其他目录的关联模式（共 64 个），同样带证据等级与英文对照。

1. 如何使用本手册

这本手册是什么

本手册是 AI Agent 工程模式的中文速查参考：193 个模式按 13 个主题组织，每个模式附一句话说明与证据等级标注。它是"遇到问题时快速定位解法"的工具，不是逐页阅读的教程。

三步使用法

1. **遇到问题**：先查第 2 章常见问题速查——15 类高频工程问题（上下文溢出、提示注入、成本过高……）直接映射到推荐模式；
2. **定位主题**：按目录页（上一页）的问题树总览，从问题句找到所属章节；
3. **查模式**：在对应章节的速查表中按证据等级选型——优先 ● 生产验证与 ★ 成熟，快速验证场景可试 ◐ 新兴。

证据等级图例

标记	含义	数量
● 生产验证	已在生产环境验证（Anthropic / OpenAI / Cursor 等）	34
★ 成熟	established / best-practice，多篇独立证据	41
◐ 新兴	emerging / rapidly-improving，证据初步但方向明确	103
○ 提案/实验	proposed / experimental，尚未经生产检验	16

> 提示：选型时把 ● 和 ★ 视为"默认可选项"，◐ 视为"值得跟踪的新方向"，○ 视为"了解即可"。多数工程问题在 ● ★ 里已有答案。

关于证据

每个模式的完整证据链（学术论文、行业实现、量化数据、参考链接）收录于上游知识库的 221 篇研究报告中，本手册是其速查视图。需要深挖单个模式时，请按模式名（表格内附英文对照）检索上游仓库：github.com/nibzard/awesome-agentic-patterns（上游署名与许可详见卷末署名页）。

2. 常见问题速查

> 遇到问题时从这里入手：先按问题定位模式，再跳到对应章节查证据等级与说明。

我遇到的问题	推荐先看
智能体总是产出低质量结果	**反思循环**（第 8 章）、**自我批判评估器循环**（第 8 章）
上下文窗口很快被填满	**上下文窗口自动压缩**（第 3 章）、**精选代码上下文窗口**（第 3 章）
智能体调用了错误的工具	**工具选择指南**（第 5 章）、**通过提示引导工具使用**（第 5 章）
担心提示注入攻击	**双 LLM 模式**（第 4 章）、**确定性威胁规则扫描**（第 9 章）
多个智能体在争抢资源	**跨领域冲突解决**（第 7 章）、**基于通道的执行排队**（第 6 章）
API 调用成本太高	**代码优先于 API 模式**（第 5 章）、**预算感知模型路由**（第 15 章）
智能体卡住了不继续	**停止钩子自动继续**（第 6 章）、**上下文窗口焦虑管理**（第 3 章）
不知道智能体做了什么	**LLM 可观测性**（第 11 章）、**详尽推理透明性**（第 4 章）
长任务执行到一半失败了	**基于文件系统的智能体状态**（第 3 章）、**扩展连贯工作会话**（第 3 章）
想让智能体从错误中学习	**事件到评测的转化合成**（第 10 章）、**Persistent Test Memory**（第 10 章）
需要人工审批关键操作	**人机协同审批框架**（第 13 章）
工具太多上下文装不下	**渐进式工具发现**（第 3 章）、**工具搜索懒加载**（第 3 章）
如何让团队共用智能体配置	**团队共享智能体配置**（第 7 章）
智能体执行了危险操作	**Hook 安全护栏**（第 9 章）、**沙箱化工具授权**（第 9 章）
需要并行处理大量任务	**工厂优先于助手**（第 6 章）、**群体迁移模式**（第 6 章）

3. 上下文（T1.1.1）

> **问题句**：有限窗口内，什么信息何时以何形式存在？ **本主题模式数**：25（另有跨主题收录 0 个）

模式	一句话说明	证据等级
智能体驱动的代码库问答与上手（Agent-Powered Codebase Q&A / Onboarding）	用智能体驱动代码库问答，加速新人上手	● 生产验证
基于向量嵌入的智能体式搜索（Agentic Search over Vector Embeddings）	用命令行工具的智能体搜索替代向量嵌入，消除索引维护	★ 成熟
上下文预算作为受治理资源（Context Budget as a Governed Resource）	将上下文 token 作为受治理的有限资源进行分配和审计	● 生产验证
上下文最小化模式（Context-Minimization Pattern）	最小化注入上下文，移除污染信息，防止提示注入	◐ 新兴
上下文窗口焦虑管理（Context Window Anxiety Management）	管理模型因上下文接近上限而产生的"提前结束"倾向	◐ 新兴
上下文窗口自动压缩（Context Window Auto Compaction）	当上下文接近窗口上限时自动压缩历史对话，保留关键信息	● 生产验证
基于 Git 的跨智能体经验共享（Cross Agent Lesson Sharing）	通过 Git 仓库在智能体间共享经验教训	● 生产验证
精选代码上下文窗口（Curated Code Context Window）	精心挑选代码文件注入上下文，减少噪声提高相关性	● 生产验证
精选文件上下文窗口（Curated File Context Window）	精选文件范围注入上下文，而非盲目加载整个代码库	★ 成熟
动态上下文注入（Dynamic Context Injection）	按需动态注入上下文，而非一次性加载所有可能需要的信息	★ 成熟
情景记忆检索与注入（Episodic Memory Retrieval Injection）	从向量数据库检索历史经验注入上下文，提供相关提示	● 生产验证
扩展连贯性工作会话（Extended Coherence Work Sessions）	在长时任务中保持智能体的连贯性和一致性	◐ 新兴
基于文件系统的智能体状态（Filesystem Based Agent State）	将中间结果持久化到文件，支持工作流恢复和故障恢复	★ 成熟
分层配置上下文（Layered Configuration Context）	按作用域分层加载配置（全局/项目/目录），自动管理上下文	★ 成熟
从执行日志合成记忆（Memory Synthesis from Execution Logs）	从执行日志中自动提取和合成可复用的经验记忆	◐ 新兴
智能体状态主动外化（Proactive Agent State Externalization）	智能体主动生成笔记外化状态，捕获决策依据和知识缺口	◐ 新兴

模式	一句话说明	证据等级
大文件的渐进式披露（Progressive Disclosure Large Files）	先加载文件元数据，再按需加载具体内容，处理超大文件	◐ 新兴
渐进式工具发现（Progressive Tool Discovery）	层级化工具发现，按需检索，支持上千工具的规模化	★ 成熟
通过精确前缀保持实现提示缓存（Prompt Caching via Exact Prefix Preservation）	保持消息前缀精确一致，最大化提示缓存命中率	◐ 新兴
面向多跳推理的 Schema 引导图检索（Schema Guided Graph Retrieval）	用共享 schema 统一图构建和检索，实现精准多跳推理	◐ 新兴
自我身份累积（Self Identity Accumulation）	跨会话累积身份档案，建立熟悉度和个性化	◐ 新兴
语义上下文过滤模式（Semantic Context Filtering）	用语义分析过滤无关上下文，只保留与当前任务相关的内容	◐ 新兴
面向代理工具的会话级上下文运行时（Session Scoped Context Runtime for Agent Tools）	缓存结构化读取并规范化工具输出，复用紧凑表示	◐ 新兴
工具搜索懒加载（Tool Search Lazy Loading）	通过搜索动态加载工具定义，而非预加载全部工具	◐ 新兴
通过 TodoWrite 实现工作记忆（Working Memory via Todos）	用 Todo 列表作为工作记忆，跟踪依赖和进度	◐ 新兴

试读版说明

你看到的是《AI Agent 工程模式速查手册》的**免费试读版**，包含：

- 封面、目录与"如何使用本手册"（证据等级图例与三步使用法）
- 常见问题速查：15 类高频工程问题 → 推荐模式
- 完整的第 3 章「上下文」（T1.1.1）：25 个模式速查 + 9 个跨主题收录，含证据等级与英文对照

完整版包含全部四部十三章、193 个模式、64 个跨主题收录、署名页与 Apache-2.0 LICENSE 附录：

☒ www.fenghaiquan-ai.com/product

问题咨询与小版本更新：support@fenghaiquan-ai.com（3 个工作日内响应）